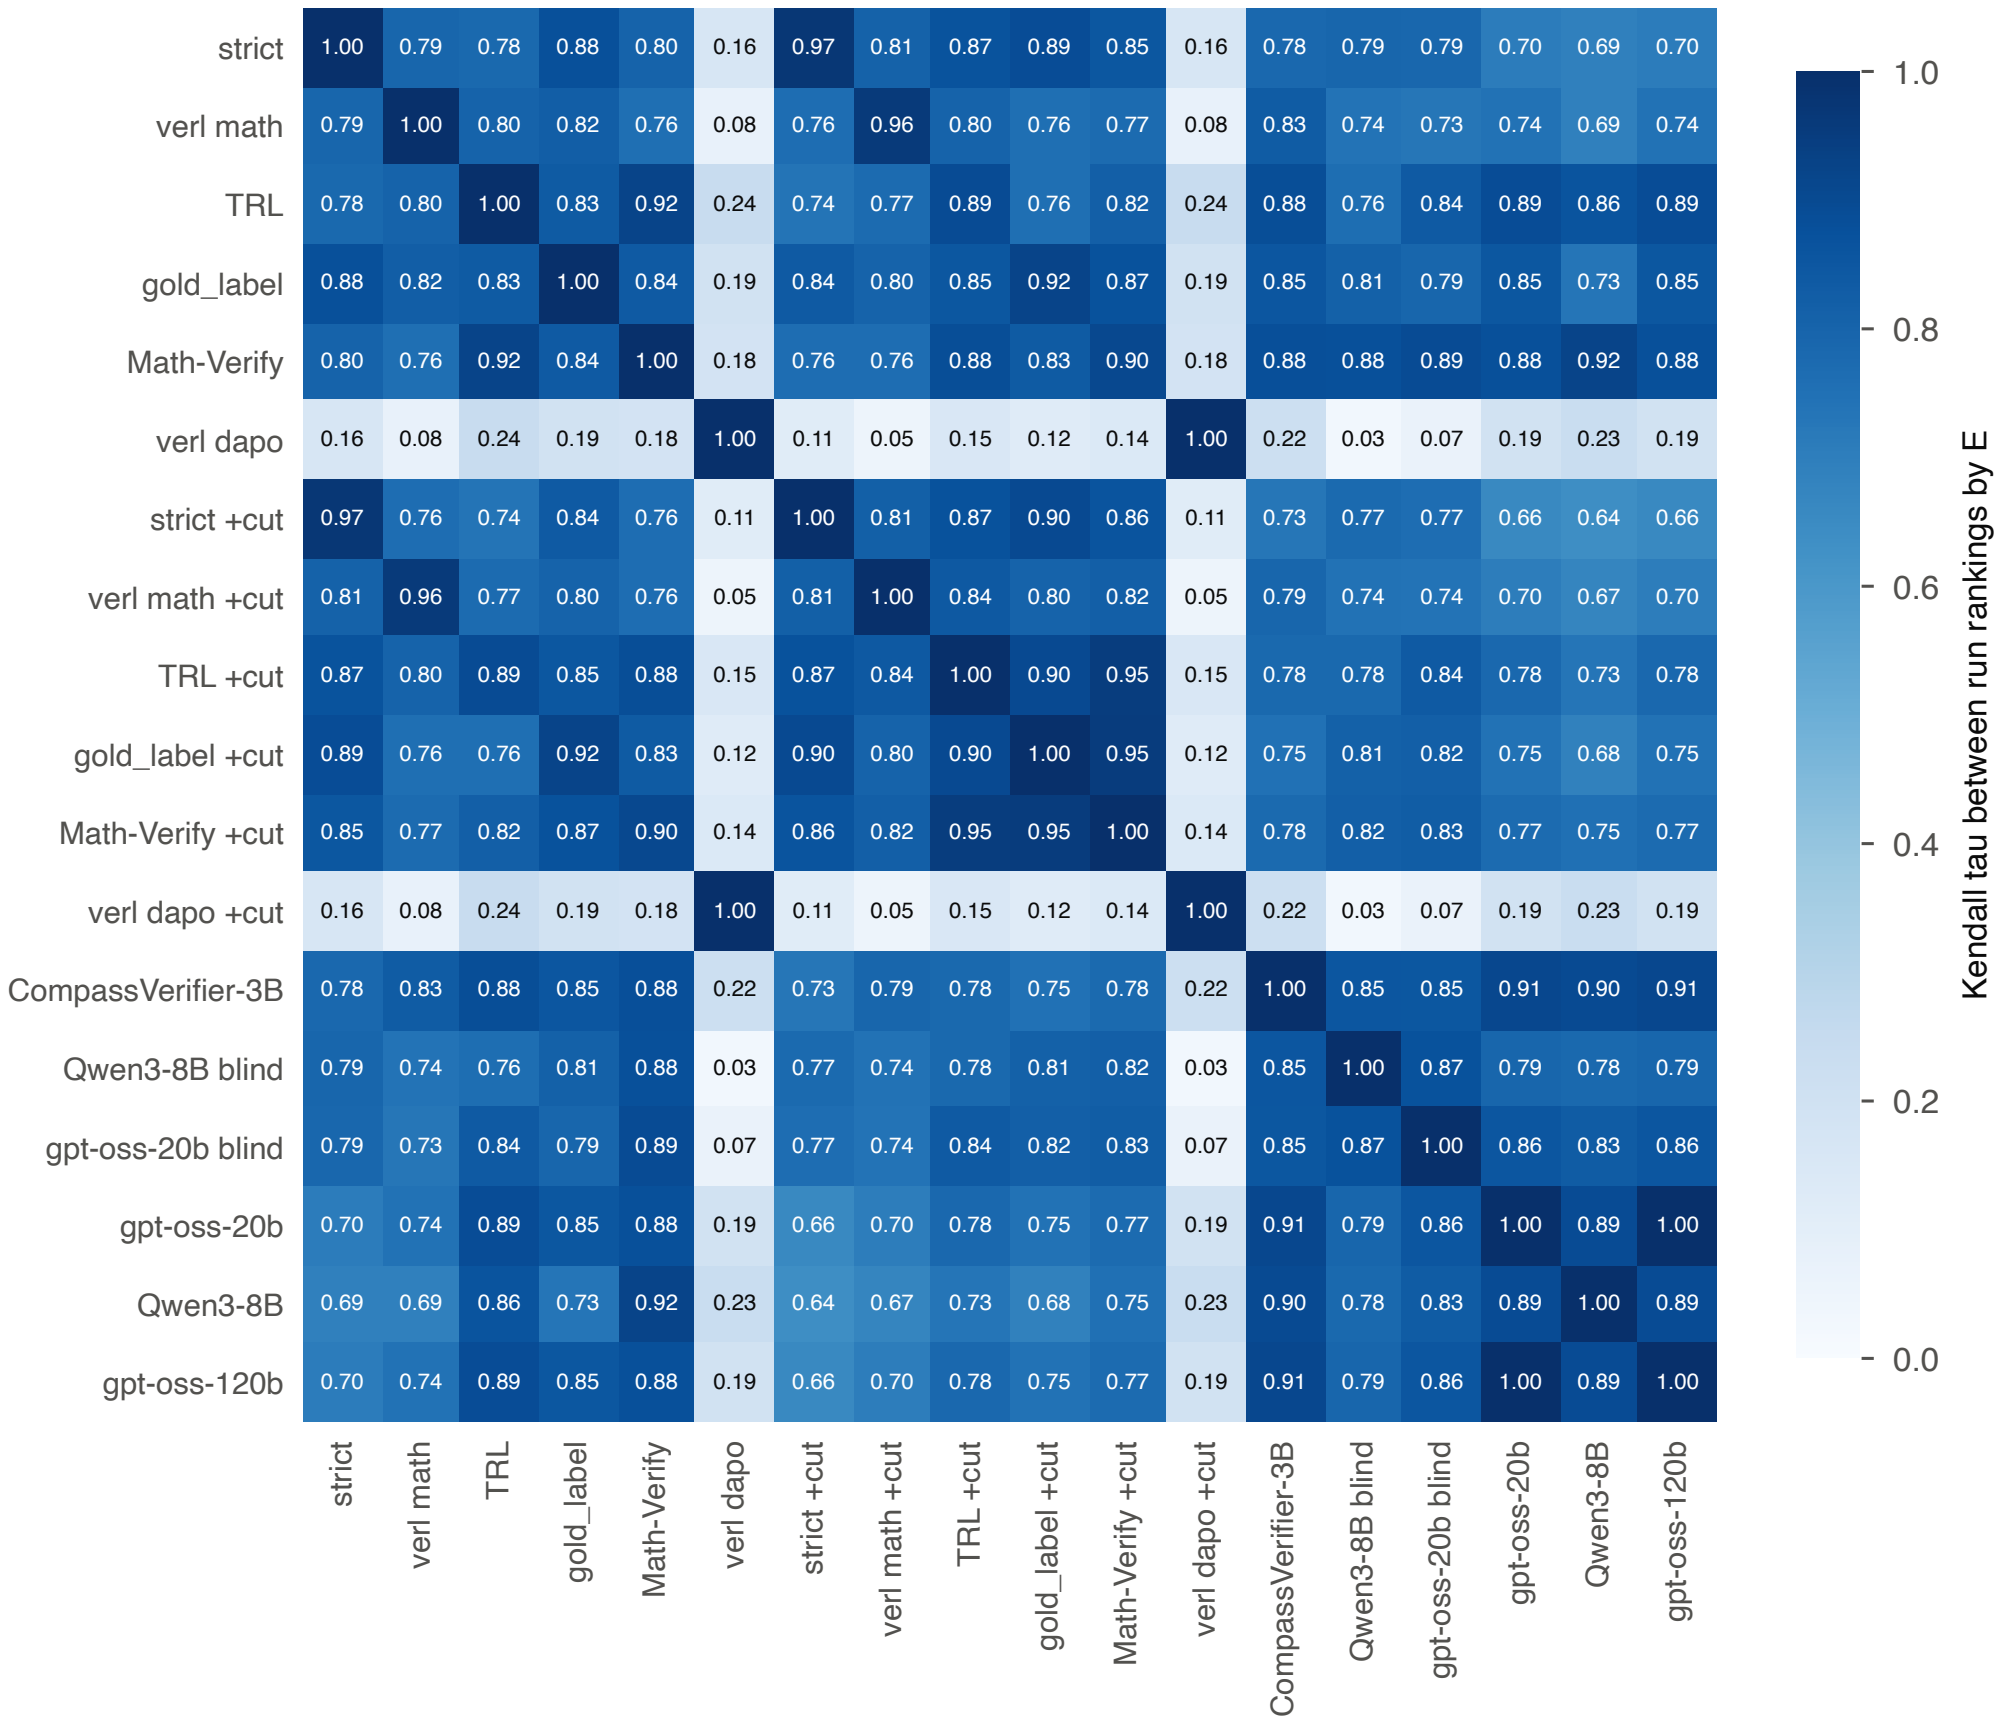
strict 1.00 0.79 0.78 0.88 0.80 0.16 0.97 0.81 0.87 0.89 0.85 0.16 0.78 0.79 0.79 0.70 0.69 0.70
verl math 0.79 1.00 0.80 0.82 0.76 0.08 0.76 0.96 0.80 0.76 0.77 0.08 0.83 0.74 0.73 0.74 0.69 0.74
TRL 0.78 0.80 1.00 0.83 0.92 0.24 0.74 0.77 0.89 0.76 0.82 0.24 0.88 0.76 0.84 0.89 0.86 0.89
gold_label 0.88 0.82 0.83 1.00 0.84 0.19 0.84 0.80 0.85 0.92 0.87 0.19 0.85 0.81 0.79 0.85 0.73 0.85
Math-Verify 0.80 0.76 0.92 0.84 1.00 0.18 0.76 0.76 0.88 0.83 0.90 0.18 0.88 0.88 0.89 0.88 0.92 0.88
verl dapo 0.16 0.08 0.24 0.19 0.18 1.00 0.11 0.05 0.15 0.12 0.14 1.00 0.22 0.03 0.07 0.19 0.23 0.19
strict +cut 0.97 0.76 0.74 0.84 0.76 0.11 1.00 0.81 0.87 0.90 0.86 0.11 0.73 0.77 0.77 0.66 0.64 0.66
verl math +cut 0.81 0.96 0.77 0.80 0.76 0.05 0.81 1.00 0.84 0.80 0.82 0.05 0.79 0.74 0.74 0.70 0.67 0.70
TRL +cut 0.87 0.80 0.89 0.85 0.88 0.15 0.87 0.84 1.00 0.90 0.95 0.15 0.78 0.78 0.84 0.78 0.73 0.78
gold_label +cut 0.89 0.76 0.76 0.92 0.83 0.12 0.90 0.80 0.90 1.00 0.95 0.12 0.75 0.81 0.82 0.75 0.68 0.75
Math-Verify +cut 0.85 0.77 0.82 0.87 0.90 0.14 0.86 0.82 0.95 0.95 1.00 0.14 0.78 0.82 0.83 0.77 0.75 0.77
verl dapo +cut 0.16 0.08 0.24 0.19 0.18 1.00 0.11 0.05 0.15 0.12 0.14 1.00 0.22 0.03 0.07 0.19 0.23 0.19
CompassVerifier-3B 0.78 0.83 0.88 0.85 0.88 0.22 0.73 0.79 0.78 0.75 0.78 0.22 1.00 0.85 0.85 0.91 0.90 0.91
Qwen3-8B blind 0.79 0.74 0.76 0.81 0.88 0.03 0.77 0.74 0.78 0.81 0.82 0.03 0.85 1.00 0.87 0.79 0.78 0.79
gpt-oss-20b blind 0.79 0.73 0.84 0.79 0.89 0.07 0.77 0.74 0.84 0.82 0.83 0.07 0.85 0.87 1.00 0.86 0.83 0.86
gpt-oss-20b 0.70 0.74 0.89 0.85 0.88 0.19 0.66 0.70 0.78 0.75 0.77 0.19 0.91 0.79 0.86 1.00 0.89 1.00
Qwen3-8B 0.69 0.69 0.86 0.73 0.92 0.23 0.64 0.67 0.73 0.68 0.75 0.23 0.90 0.78 0.83 0.89 1.00 0.89
gpt-oss-120b 0.70 0.74 0.89 0.85 0.88 0.19 0.66 0.70 0.78 0.75 0.77 0.19 0.91 0.79 0.86 1.00 0.89 1.00
strict
verl math
TRL
gold_label
Math-Verify
verl dapo
strict +cut
verl math +cut
TRL +cut
gold_label +cut
Math-Verify +cut
verl dapo +cut
CompassVerifier-3B
Qwen3-8B blind
gpt-oss-20b blind
gpt-oss-20b
Qwen3-8B
gpt-oss-120b
1.0
0.8
0.6
0.4
0.2
0.0
Kendall tau between run rankings by E